



МИНОБРНАУКИ РОССИИ

**Федеральное государственное бюджетное образовательное учреждение
высшего образования**

«МИРЭА - Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий (ИТ)

Кафедра прикладной математики (ПМ)

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ №8

по дисциплине

«Технологии и инструментарий анализа больших данных»

Выполнил: студент группы ИКБО-33-22

Шило Ю. С.

Проверил: преподаватель

Юрченков И.А.

Практическая работа выполнена «__» _____ 2025 г.

(подпись студента)

Зачтено «__» _____ 2025 г.

(подпись преподавателя)

Москва 2025

Практическая работа №8

1. Настроить виртуальную машину Ubuntu Server 22.04.5 LTS в системе виртуализации операционных систем, а также настроить Docker контейнеры PostgreSQL, Arundata Cluster Manager совместно с бандлами для кластера и мониторинга (Prometheus, Grafana). **(1 балл)**

В отчет прикрепить скриншот с интерфейса ADCM на странице Cluster->Overview где показано, что все сервисы подняты и работают в штатном режиме.

2. Создать базу данных ecommerce и развернуть public схему таблиц, на основе приложенного скрипта, для хранения данных транзакций в PostgreSQL посредством postgresql-client (DBEaver или любой другой админ баз данных). Для каждой таблицы сделать импорт данных посредством импорта из CSV-файла в следующем порядке **(1 балл)**:

- geolocation – geolocation.csv
- leads_closed – leads_closed.csv
- product_category_name_translation – product_category_name_translation.csv
- sellers - sellers.csv
- customers – customers.csv
- leads_closed – leads_closed.csv
- products – products.csv
- orders – orders.csv
- order_items – order_items.csv
- order_reviews – order_reviews.csv
- order_payments – order_payments.csv

В отчет прикрепить визуализацию схемы таблиц, полученную в консоли командной строки или в виде диаграммы в админе баз данных (например DBEaver).

3. Написать запросы на языке SQL для базы данных ecommerce для получения данных по следующим заданиям:

3.1. ТОП-10 категорий по выручке, с переводом (0,5 балла)

Нужно определить десять товарных категорий с наибольшим оборотом продаж. Для каждой категории требуется посчитать сумму цен всех проданных позиций (это и есть выручка/GMV категории), количество уникальных заказов, в которых встречались товары этой категории, и общее число товарных позиций. Дополнительно к исходному названию категории нужно вывести её англоязычный перевод из словаря переводов. Итоговый набор данных должен быть отсортирован по выручке по убыванию и ограничен первыми десятью строками.

```
SELECT
  p.product_category_name AS category_name,
  t.product_category_name_english AS category_name_english,
  SUM(oi.price) AS revenue_gmv,
  COUNT(DISTINCT oi.order_id) AS unique_orders,
  COUNT(*) AS total_items
FROM
  order_items oi
JOIN
  products p ON oi.product_id = p.product_id
LEFT JOIN
  product_category_name_translation t ON p.product_category_name = t.product_category_name
WHERE
  p.product_category_name IS NOT NULL
GROUP BY
  p.product_category_name, t.product_category_name_english
ORDER BY
  revenue_gmv DESC
LIMIT 10;
```

category_name	category_name_english	revenue_gmv	unique_orders	total_items
beleza_saude	health_beauty	1258681.34	8836	9670
relogios_presentes	watches_gifts	1205005.68	5624	5991
cama_mesa_banho	bed_bath_table	1036988.68	9417	11115
esporte_lazer	sports_leisure	988048.97	7720	8641
informatica_acessorios	computers_accessories	911954.32	6689	7827
moveis_decoracao	furniture_decor	729762.49	6449	8334
cool_stuff	cool_stuff	635290.85	3632	3796
utilidades_domesticas	housewares	632248.66	5884	6964
automotivo	auto	592720.11	3897	4235
ferramentas_jardim	garden_tools	485256.46	3518	4347
beleza_saude	health_beauty	1258681.34	8836	9670
relogios_presentes	watches_gifts	1205005.68	5624	5991
cama_mesa_banho	bed_bath_table	1036988.68	9417	11115
esporte_lazer	sports_leisure	988048.97	7720	8641

3.2. Платежное поведение (0,5 балла)

Нужно сравнить используемые способы оплаты. По каждому типу оплаты требуется вывести количество зарегистрированных платежей, среднее число рассрочек (если применимо), средний размер платежа и долю заказов, в которых встречается данный способ оплаты.

Под долей заказов понимается отношение числа уникальных заказов, где зафиксирован хотя бы один платёж данного типа, к общему числу уникальных заказов, по которым известны записи об оплате.

Следует учитывать, что у одного заказа может быть несколько платежей. Доля считается на уровне «есть/нет» для типа оплаты в заказе.

```
WITH order_payment_stats AS (  
    SELECT  
        payment_type,  
        COUNT(*) AS payment_count,  
        AVG(payment_installments) AS avg_installments,  
        AVG(payment_value) AS avg_payment_value,  
        COUNT(DISTINCT order_id) AS orders_with_payment_type  
    FROM order_payments  
    GROUP BY payment_type  
)  
  
total_orders AS (  
    SELECT COUNT(DISTINCT order_id) AS total_orders_count  
    FROM order_payments  
)  
  
SELECT  
    ops.payment_type,  
    ops.payment_count,  
    ROUND(ops.avg_installments, 2) AS avg_installments,  
    ROUND(ops.avg_payment_value, 2) AS avg_payment_value,  
    ops.orders_with_payment_type,  
    ROUND(  
        ops.orders_with_payment_type * 100.0 / tot.total_orders_count,  
        2  
    ) AS order_percentage  
FROM order_payment_stats ops  
CROSS JOIN total_orders tot  
ORDER BY ops.payment_count DESC;
```

payment_type	payment_count	avg_installments	avg_payment_value	orders_with_payment_type	order_percentage
credit_card	76795	3.51	163.32	76505	76.94
boleto	19784	1.00	145.03	19784	19.90
voucher	5775	1.00	65.70	3866	3.89
debit_card	1529	1.00	142.57	1528	1.54
not_defined	3	1.00	0.00	3	0.00

3.3. Зависимость оценки от скорости доставки (0,5 балла)

Нужно изучить, как длительность доставки коррелирует с оценками в отзывах. Для каждого заказа с отзывом и известной фактической датой доставки рассчитывается длительность доставки в днях как разница между датой доставки клиенту и датой покупки.

Далее каждый заказ попадает в один из трёх интервалов длительности:

- **до пяти дней включительно,**
- **от шести до десяти дней включительно,**
- **более десяти дней.**

Для каждого интервала требуется посчитать количество заказов и среднюю оценку из отзывов. Итог должен содержать три строки — по одному агрегату на интервал — в логическом порядке от самого быстрого интервала к самому длительному.

```
WITH delivery_data AS (
  SELECT
    o.order_id,
    o.order_purchase_timestamp,
    o.order_delivered_customer_date,
    r.review_score,
    EXTRACT(DAY FROM
      (o.order_delivered_customer_date - o.order_purchase_timestamp)
    ) AS delivery_duration_days
  FROM orders o
  JOIN order_reviews r ON o.order_id = r.order_id
  WHERE o.order_delivered_customer_date IS NOT NULL
    AND o.order_purchase_timestamp IS NOT NULL
    AND r.review_score IS NOT NULL
),
delivery_intervals AS (
  SELECT
    order_id,
    review_score,
    CASE
      WHEN delivery_duration_days <= 5 THEN 'до 5 дней'
      WHEN delivery_duration_days BETWEEN 6 AND 10 THEN '6-10 дней'
      ELSE 'более 10 дней'
    END AS delivery_interval
  FROM delivery_data
  WHERE delivery_duration_days >= 0 -- исключаем некорректные данные
)
SELECT
  delivery_interval,
  COUNT(order_id) AS orders_count,
  ROUND(AVG(review_score), 2) AS avg_review_score
FROM delivery_intervals
GROUP BY delivery_interval
ORDER BY
  CASE
    WHEN delivery_interval = 'до 5 дней' THEN 1
    WHEN delivery_interval = '6-10 дней' THEN 2
    ELSE 3
  END;
END;
```

delivery_interval	orders_count	avg_review_score
до 5 дней	19008	4.43
6-10 дней	32408	4.35
более 10 дней	43451	3.90

3.4. Эффективность продавцов (0,5 балла)

Нужно получить рейтинг продавцов по активности и базовым бизнес-показателям. Для каждого продавца считается количество уникальных заказов, в которых он участвовал, число уникальных клиентов, которым он продал хотя бы одну позицию, общее число проданных товарных позиций, совокупный оборот по этим позициям (сумма цен) и средняя стоимость доставки на позицию (среднее от значений стоимости фрахта по позициям). Затем формируется топ-10 продавцов, отсортированный по числу заказов по убыванию. В отчёте по каждому продавцу должны присутствовать перечисленные метрики.

```
SELECT
  s.seller_id,
  COUNT(DISTINCT oi.order_id) AS unique_orders_count,
  COUNT(DISTINCT o.customer_id) AS unique_customers_count,
  COUNT(*) AS total_items_sold,
  ROUND(SUM(oi.price), 2) AS total_revenue,
  ROUND(AVG(oi.freight_value), 2) AS avg_freight_per_item
FROM order_items oi
JOIN orders o ON oi.order_id = o.order_id
JOIN sellers s ON oi.seller_id = s.seller_id
GROUP BY s.seller_id
ORDER BY unique_orders_count DESC
LIMIT 10;
```


seller_id	unique_orders_count	unique_customers_count	total_items_sold	total_revenue	avg_freight_per_item
6560211a19b47992c3666cc44a7e94c0	1854	1854	2033	123304.83	13.75
4a3ca9315b744ce9f8e9374361493884	1806	1806	1987	200472.92	17.65
cc419e0650a3c5ba77189a1882b7556a	1706	1706	1775	104288.42	14.46
1f50f920176fa81dab994f9023523100	1404	1404	1931	106939.21	18.21
da8622b14eb17ae2831f4ac5b9dab84a	1314	1314	1551	160236.57	16.09
955fee9216a65b617aa5c0531780ce60	1287	1287	1499	135171.70	16.97
7a67c85e85bb2ce8582c35f2203ad736	1160	1160	1171	141745.53	17.85

ea8482cd71df3c1969d7b9473ff13abc	1146	1146	1203	37177.52	14.58
4869f7a5dfa277a7dca6462dcf3b52b2	1132	1132	1156	229472.63	17.45
3d871de0142ce09b7081e2b9d1733cb1	1080	1080	1147	94914.20	19.56

4. Построить дашборд в Grafana для визуализации данных из ecommerce на основе следующих задач и нескольких ваших созданных визуализаций:

4.1. Динамика числа заказов (0.5 балла)


Нужно показать динамику общего числа заказов по месяцам. Для каждого месяца в хронологическом порядке считается количество уникальных заказов, оформленных в этот месяц. Полученный временной ряд должен быть представлен линией, позволяющей увидеть рост, падения или сезонность количества заказов.



Больше всего заказов произошло в декабре 2017 года. В исходных данных начало идет с 2016 года, а заканчивается в 2018 году.

4.2. Количество заказов по оценкам (0.5 балла)

Нужно построить распределение количества заказов по оценкам клиентов. Для этого все отзывы группируются по выставленной оценке, и для каждой категории оценки подсчитывается количество заказов, получивших такую оценку. Результат следует отобразить в виде отдельных вертикальных столбцов, показывающих частоту каждой оценки.



4.3. Распределение способов оплаты (0.5 балла)

Необходимо показать распределение способов оплаты заказов. Для этого подсчитывается количество уникальных заказов, оплаченных каждым способом. Итоговые доли по каждому методу оплаты отображаются на круговой диаграмме, где сегменты представляют разные способы оплаты, а их размер соответствует доле.




4.4. Топ товарных категорий по объему продаж (0.5 балла)

Задача заключается в том, чтобы вывести топ-10 товарных категорий по общему объёму продаж. Для каждой категории суммируется стоимость всех

товарных позиций, после чего выбираются десять лидеров. Визуализация выполняется в виде горизонтальных столбцов (линеек), что позволяет удобно сравнивать категории между собой по длине.



4.5 Ваши дополнительные две визуализации по 1 баллу каждый + дашборд отдельно в виде скриншотов, в котором умещается ваш дашборд. (2 балла)



Отчет по работе представить в виде документа, содержащего в себе задания и ответы на задания в заданном формате в данном файле.